TEORIA DE COLAS

Las situaciones en las que se han aplicado la Teoría de Colas son las siguientes, por ejemplo:

1. Congestionamiento de tráfico automotor
2. Estudio de tráfico aéreo en una aeropuerto.
3. Estudios de la Producción
4. Control de Inventarios
5. Capacidad de la sala de espera de un hospital
6. El número de cajas que deben operar en un banco o supermercado

Las líneas de espera son fenómenos **ESTOCASTICOS** (probabilísticos) para las que se establecerán las ecuaciones de estado, las cuales son utilizadas para el cálculo de diversas magnitudes medias o promedios

INTRODUCCIÓN

Muchas industrias de servicios tienen un **SISTEMAS DE COLAS**, en el que los productos o "clientes" llegan a una estación, esperan en una "fila" (o cola), obtienen algún tipo de servicio y luego salen del sistema.

Los modelos de sistemas de colas se pueden usar para responder preguntas como las siguientes:

1. ¿Qué fracción de tiempo está ocioso cada servidor?
2. ¿Cuál es el número esperado de clientes presentes en cola?
3. ¿Cuál es el tiempo promedio que un cliente espera en cola?
4. ¿Cuál es la distribución de probabilidad del número de clientes presentes en cola?
5. ¿Cuál es la distribución de probabilidad del tiempo de espera de un cliente?

CUALIFICACIÓN Y CUANTIFICACIÓN DE UNA COLA DE ESPERA

La situación ideal es cuando los servidores están esperando temporalmente a los clientes y estos solo esperan servicio momentáneamente.

Este es el caso típico de un sistema balanceado que tiende a un sistema estable o en equilibrio.

La teoría de líneas de espera tiene los siguientes objetivos:

A. **Caracterizar cuantitativamente y cualitativamente a una cola.**
B. **Determinar los niveles adecuados de ciertos parámetros del sistema que equilibran el costo de la espera en cola con el costo asociado al consumo de recursos.**

La cuantificación de una línea de espera se puede hacer a través de un análisis matemático o de un proceso de simulación.

El primer enfoque produce resultados óptimos pero requiere de suposiciones estrictas respecto a: la naturaleza de llegada de los clientes, el tipo de servicio, el número de servidores y la estructura del sistema

El proceso de simulación tiene una aplicación más general que la del análisis matemático, ya que prácticamente se lo puede utilizar para cualquier sistema. La desventaja es que es mucho más costoso.

En el sistema de Colas el término “cliente” se usa para referirse por ejemplo:

- Gente esperando que se desocupe alguna línea telefónica.
- Máquinas que deben ser reparadas.
- Aviones esperando para aterrizar.
- Gente esperando en la cola de un cajero de un supermercado, de un banco, etc.

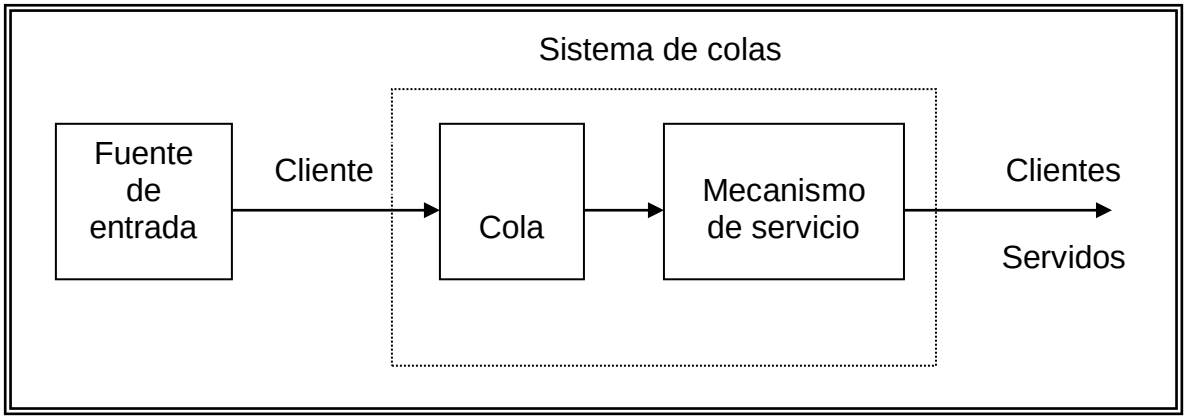
El término instalaciones de “servicio” se utiliza en sistema de colas para referirse a, por ejemplo:

- Líneas telefónicas
- Talleres de reparación
- Pistas de un aeropuerto.
- Cajas de pago, etc,

ESTRUCTURA BÁSICA DE UNA LÍNEA DE ESPERA

La estructura física de líneas de espera consiste en tres componentes:

- Una o varias fuentes de llegadas (clientes),
- Líneas de espera (colas) y
- Una instalación de servicio consistente en una o varias partes (servidores)



En la siguiente tabla se citan algunos ejemplos:

Ejemplos De Sistemas De Colas			
Situación	**Llegada**	**Cola**	**Mecanismo de Servicio**
Aeropuerto	Aviones	Aviones en espera para aterrizar	Pista
Aeropuerto	Pasajeros	Sala de espera	Avión
Departamento de bomberos	Alarma de incendio	Incendios	Departamento de bomberos
Compañía telefónica	Números marcados	Llamadas	Conmutador
Lavado de autos	Autos	Autos sucios	Mecanismo de lavado
La corte	Casos	Casos atrasados	Juez
Panadería	Clientes	Clientes con números	Vendedor
Oficina de correo	Cartas	Buzón	Carteros
Fábrica	Subensamble	Inventario en proceso	Estación de trabajo
Hospital	Pacientes	Personas enfermas	Hospital

PROCESO BÁSICO DE COLAS

El proceso básico supuesto por la mayor parte de los modelos de colas es el siguiente. Los **clientes** que requieren un **servicio** se generan a través del tiempo en una fuente de entrada. Estos clientes entran al sistema y se unen a una cola. En determinado momento se selecciona un miembro de la cola, para proporcionarle el servicio, mediante alguna regla conocida como disciplina de cola (o disciplina de servicio). Después, en un mecanismo de servicio se lleva a cabo el servicio requerido por el cliente luego de lo cual el cliente sale del Sistema de colas. Los clientes que se forman en una cola lo hacen en un área de espera.

CARACTERÍSTICAS DE UN SISTEMA DE COLAS

FUENTE DE ENTRADA (POBLACIÓN POTENCIAL)

Una característica de la fuente de entrada es su tamaño. El tamaño es el número total de clientes que pueden requerir servicio en determinado momento, es decir, el número total de clientes potenciales distintos.

Puede suponerse que el tamaño es **infinito** o **finito** (de modo que también se dice que la fuente de entrada es ilimitada o limitada). Como los cálculos son mucho más sencillos para el caso infinito, esta suposición se hace muy seguido cuando el tamaño real sea un número fijo relativamente grande,

También se debe especificar el patrón estadístico mediante el cual se generan los clientes a través del tiempo. La suposición normal es que se generan de acuerdo a un **proceso Poisson**, es decir, el número de clientes que llegan hasta un tiempo específico tiene una distribución Poisson, este caso corresponde a aquel cuyas llegadas al sistema ocurren de manera aleatoria pero con cierta tasa media fija y sin importar cuántos clientes están en el sistema (por lo que el tamaño de la fuente de entrada es infinito). Una suposición equivalente es que la distribución de probabilidad del tiempo que transcurre **entre dos llegadas** consecutivas es **exponencial**.

NÚMERO DE CLIENTES QUE PUEDEN ESPERAR EN LA COLA.

El número de clientes que pueden esperar en la cola puede ser finito o infinito.

LA ESPERA DE LOS CLIENTES EN COLA

Los clientes pueden esperar, en una cola o en varias, en las cuales pueden tener la opción de cambiarse o no. Por ejemplo, en algunos bancos los clientes deben hacer una sola cola, pero en otros, pueden escoger la cola en donde formarse. Si hay varias colas en una instalación, es importante conocer si se permite a los clientes cambiar de cola o no. En la mayor parte de los sistemas con colas múltiples se permite el cambio, pero no se lo recomienda, por ejemplo en una casilla para peaje. Cuando hay varias colas con frecuencia los clientes se forman en la más corta. Desafortunadamente en muchos casos, como en un supermercado, es difícil definir la cola más corta.

TIEMPO ENTRE LLEGADAS

Es el tiempo transcurrido entre la llegada de un cliente y el inmediatamente anterior. Este intervalo de tiempo puede ser una constante (determinístico) o una variable aleatoria (probabilístico) cuya distribución de probabilidad se puede conocer o no. El enfoque de análisis matemático de las líneas de espera, está muy bien desarrollado, cuando la distribución de llegada es Poisson.

Cuando las llegadas no son independientes (sería el caso de un grupo de pacientes que llegan a un centro de emergencia, cuando éstos sufrieron el mismo accidente) se utiliza el enfoque de la simulación.

TIEMPO DE SERVICIO

En general cada cliente que ingresa al sistema de atención no siempre lo hace en búsqueda de un servicio similar al que motivó el ingreso de los otros clientes que lo preceden o lo suceden.

El tiempo de servicio puede ser una constante o una variable, puede ser además aleatoria, dependiente o independiente, cuya distribución de probabilidad se puede o no conocer.

El enfoque matemático ha proporcionado resultados a las líneas de espera cuando el tiempo de servicio, tiene una distribución exponencial negativa o una distribución de ERLANG. Para otras distribuciones, se utiliza el enfoque de simulación.

Se dice que el tiempo de servicio es dependiente, cuando varía (se alarga o se acorta) por factores de presión del sistema (por ejemplo, las quejas de la gente que espera), y es independiente cuando la duración del servicio no se afecta por este tipo de presiones.

DISCIPLINA DE COLAS

Otra característica del proceso de colas es la disciplina de colas, es decir, la forma en que los clientes que esperan son seleccionados para ser atendidos. A continuación presentaremos algunas de las formas más comunes.

- ✓ **Primero en entrar, primero en salir (FIFO):** los clientes son atendidos en el orden en que van llegando a la fila. Los clientes de un banco y de un supermercado, por ejemplo, son atendidos de esta manera.

- ✓ **Ultimo en entrar, primero en salir (LIFO):** el cliente que ha llegado más recientemente es el primero en ser atendido. Un ejemplo de esta disciplina se da en un proceso de producción en el que los productos llegan a una estación de trabajo y son apilados uno encima de otro. El trabajador elige, para su procesamiento, el producto que está en la cima de la pila, que fue el último que llegó para ser procesado o para brindarle un servicio.

- ✓ **Selección de prioridad:** a cada cliente que llega se le da una prioridad y se elige según ésta para brindarle el servicio. Un ejemplo de esta disciplina son los pacientes que llegan a la sala de urgencias de un hospital. Mientras más severo sea el caso, mayor será la prioridad del cliente.

- ✓ **Disciplina SIRO (servicio en orden aleatorio):** a veces, el orden en el que llegan los clientes no tiene efecto alguno sobre el orden en el que se les sirve. Este sería el caso si el siguiente cliente en ser atendido se selecciona al azar de entre los que están esperando para ser atendidos.

NÚMERO DE SERVIDORES

El número de servidores o canales puede ser uno o más.

ESTADO DE UN SISTEMA

El estado de un sistema puede ser estable o transitorio. Por ejemplo: considere la cantidad de tiempo que los clientes tienen que esperar en un banco durante el día. Cuando el banco abre a la mañana no hay nadie en el sistema, de modo que el primer cliente es atendido de inmediato. Conforme van llegando más clientes, lentamente se va formando la cola y la cantidad de tiempo que tienen que esperar empieza a aumentar. A medida que avanza el día, el sistema llega a una condición en la que el efecto de la falta inicial de clientes ha sido eliminado y el tiempo de espera de cada cliente ha alcanzado un nivel estable. La fase inicial conserva los efectos de las condiciones iniciales, a estos lo llamamos fase transitoria. Después que los

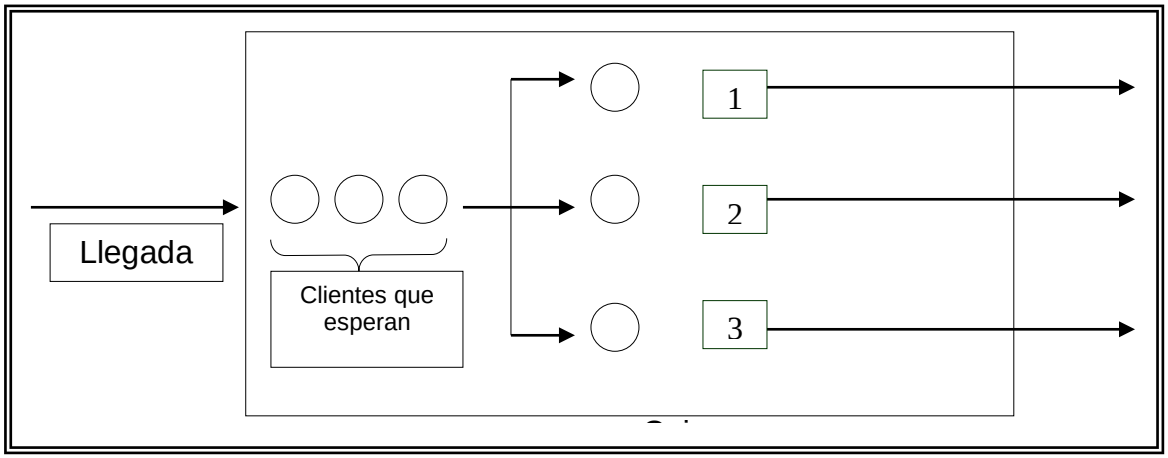
efectos de las condiciones iniciales fueron eliminados, el sistema entra en un estado estable, que lo hace independiente del tiempo.

Aquí se cubre sólo la condición estable, y específicamente aquellos casos donde en un período determinado sólo puede ocurrir una entrada al sistema (nacimiento) y una salida del mismo (muerte). De ahí que matemáticamente se conozca a estos procesos estables como procesos de nacimiento y muerte.

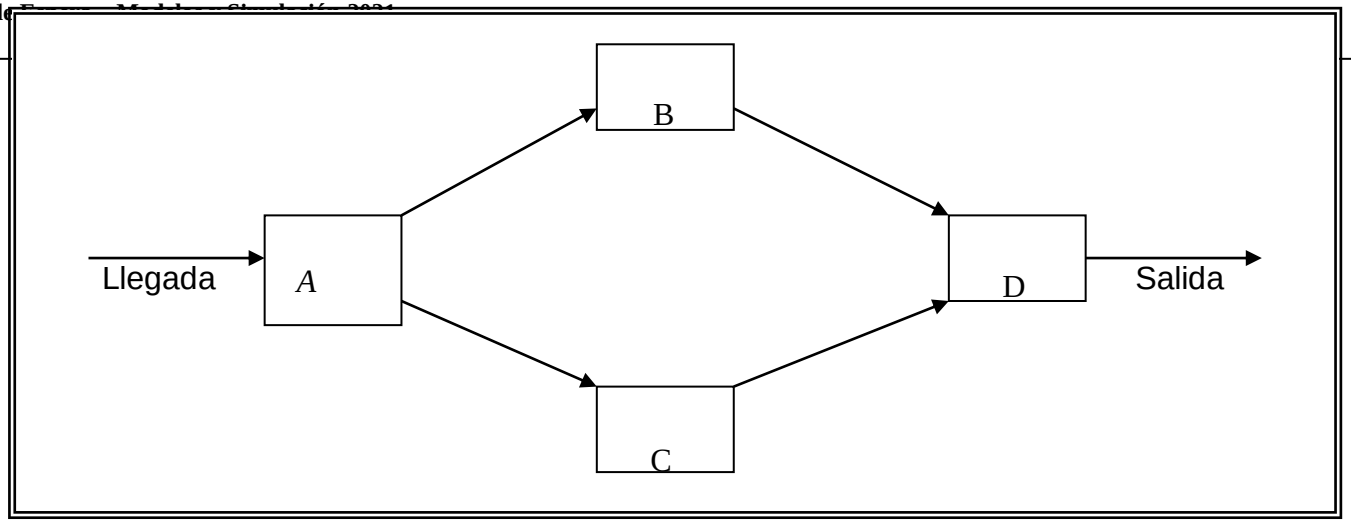
PROCESOS DE SALIDA

Es la forma en que los productos o los clientes abandonan un Sistema de colas. Pueden ser de los siguientes dos tipos:

1. Los elementos abandonan completamente el sistema después de ser atendidos en un solo centro o estación de trabajo, lo que tiene como resultado un sistema de colas de un paso. Por ejemplo, como se muestra en la figura, los clientes de un banco esperan en una sola fila, son atendidos por uno de los tres cajeros y después abandonan el sistema.



2. Los productos, una vez que son procesados en una estación de trabajo, son trasladados a alguna otra para someterlos a otro tipo de proceso, lo que tiene como resultado una red de colas ó Cascada. Por ejemplo, los productos que se muestran en la figura primero son procesados en la estación de trabajo A y después enviados a la estación B o C. Los productos terminados en ambas estaciones, B y C, luego son procesados en la estación D, antes de abandonar el sistema.



Cuando los problemas de colas tienen tiempos aleatorios entre llegadas o tiempos aleatorios de servicio, o ambos, ocurrirán colas con longitudes aleatorias. Si no hay unidades esperando la mayor parte del tiempo, entonces los servidores tenderán a estar ociosos durante una gran parte del tiempo. Si existen costos asociados con canales ociosos de servicio, entonces esto es indeseable. Por otra parte, si los servidores están ocupados y existen colas la mayor parte del tiempo, con frecuencia los clientes tendrán que esperar antes de recibir servicio. Si los tiempos de espera son prolongados, también puede dar como resultado costos tangibles o intangibles tales como demoras de producción (mecánicos esperando partes o herramientas, máquinas

paradas), deterioro de ciertos atributos de las llegadas (camiones de cemento o barcos con frutas en espera de descarga, pacientes en espera de cirugía) o pérdida de reputación (los clientes se impacientan). El objetivo en los modelos de colas es diseñar una prestación tal, que la suma de todos los costos asociados con la operación del sistema se minimice.

TIPOS DE SISTEMAS DE COLAS

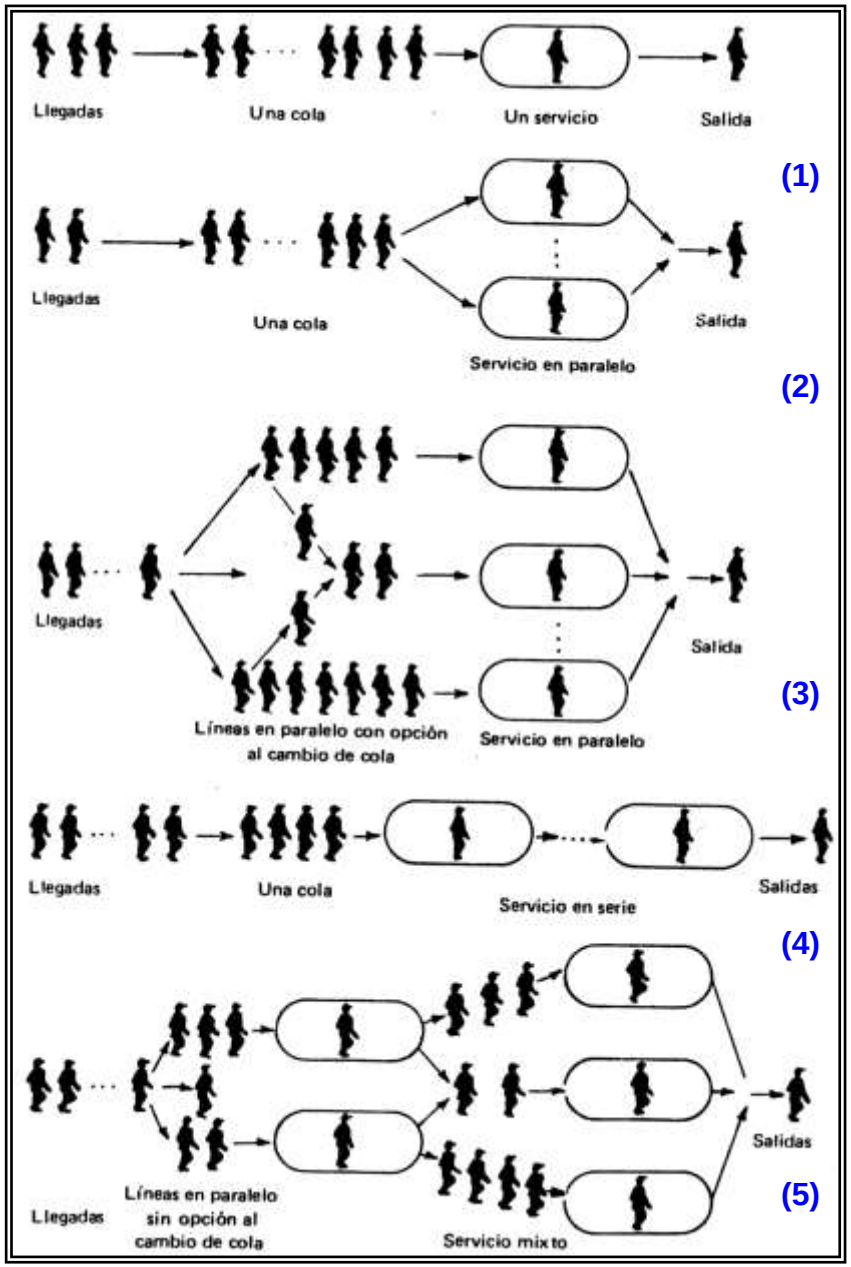
Los bancos casi siempre tienen más de un cajero, cada uno con una línea de espera separada. Con frecuencia los aeropuertos tienen más de una pista de aterrizaje. El correo maneja las cartas en base a prioridades: simple, expreso, certificado, etc. Las fábricas generalmente tienen una serie de estaciones de trabajo, no sólo una. Permitiendo que varíen el número de colas y el número de servidores, pueden hacerse los diagramas de los tipos de sistemas de la siguiente forma.

1. Una cola-un servidor. Existe una fuente a partir de la cual fluyen los clientes, una línea de espera (cola) y existe además un único centro de servicio. Por ejemplo en una boletería de un cine en donde se venden boletos de acuerdo a cómo llegan los espectadores.
2. Mono Cola - Multicanal. Existe una fuente a partir de la cual fluyen los clientes, una sola línea de espera, dos o más canales en paralelos constituyen el centro de servicio, asegura el proceso "Primero en entrar, primero en salir". Por ejemplo en una peluquería con 5 sillones (5 peluqueros) que prestan sus servicios siguiendo una política de atender a los clientes en el orden con que llegan al establecimiento (no se aceptan reservaciones).
3. MultiCola – Multicanal – Con opción de Cambio. Existe una fuente a partir de la cual surgen los clientes, colas independientes con opción a elección y cambio, canales independientes constituyen el centro de servicio; no asegura el proceso "Primero en entrar primero en salir". Un ejemplo es el caso de un banco, donde existen 18 cajas y los clientes se forman en la cola que más les convenga, con la opción de cambiarse de una cola a otra.
4. MultiCola – Multicanal – Con opción de Cambio. Es el caso de cualquier trámite burocrático, por ejemplo, la oficina de préstamos a corto plazo donde existen 5

ventanillas de recepción de documentos, de acuerdo a la inicial del apellido paterno (A-E, F-J, K-O, P-T, U-Z).

5. Una cola-servidores múltiples en cascada. Por ejemplo en una embotelladora, las botellas usadas se esterilizan, después pasan al llenado del líquido, tapado, etiquetado y empaquetado. Se cuenta con una sola esterilizadora, una sola máquina de llenado, una tapadora, una etiquetadora y una empaquetadora.
6. Colas múltiples-servidores múltiples en sistema mixto. Existe una fuente a partir de la cual surgen los clientes, líneas en paralelo sin opción a cambio de cola, canales de despacho en paralelo – serie constituyendo el centro de servicio. Un caso sería el mismo ejemplo anterior, pero con más de una unidad de las diferentes máquinas que se mencionaron.

En la figura se muestran estas variantes.


Llegadas
Una cola
Un servicio
Salida
(1)
Llegadas
Una cola
Salida
Servicio en paralelo
(2)
Llegadas
Salida
Líneas en paralelo con opción al cambio de cola
Servicio en paralelo
(3)
Llegadas
Una cola
Salidas
Servicio en serie
(4)
Salidas
Llegadas
Líneas en paralelo sin opción al cambio de cola
Servicio mixto
(5)

UN PROCESO DE COLAS ELEMENTAL

Como ya se ha sugerido, la teoría de colas se aplica a muchos tipos diferentes de situaciones. El tipo que más prevalece es el siguiente: una sola línea de espera (que puede estar vacía en ciertos momentos) se forma frente a una instalación de servicio, dentro de la cual se encuentran uno o más servidores. Cada cliente generado por una fuente de entrada recibe el servicio de uno de los servidores.

En muchos casos los servidores pueden ser una máquina o una parte del equipo, con esta misma línea de ideas, los clientes en la cola no tienen que ser personas. Por ejemplo: pueden ser unidades que esperan ser procesadas en una cierta máquina. No es necesario que de hecho se forme físicamente una línea de espera delante de una estructura física que constituye la instalación de servicio; es decir, los miembros de la cola pueden estar dispersos en un área mientras esperan que el servidor venga a ellos, como las máquinas que esperan reparación.

NOTACIÓN EN LA TEORÍA DE LÍNEAS DE ESPERA

Se designa por

λ al número promedio de llegadas al sistema por unidad de tiempo (minuto, hora, día, etc.)

μ al número promedio de servicios del sistema por unidad de tiempo.

El cociente λ/μ, denotado por ρ, representa el factor de tráfico. Si $\rho > 1$, llegan más clientes al sistema por unidad de tiempo de los que se les puede dar servicio y, por lo tanto, se forma una línea de espera en crecimiento sin limite. El factor $\rho > 1$ indica la necesidad de añadir al sistema más servidores, S, hasta que se logre que el factor de utilización (o de uso) del sistema con servidores múltiples, sea menor a uno, es decir:

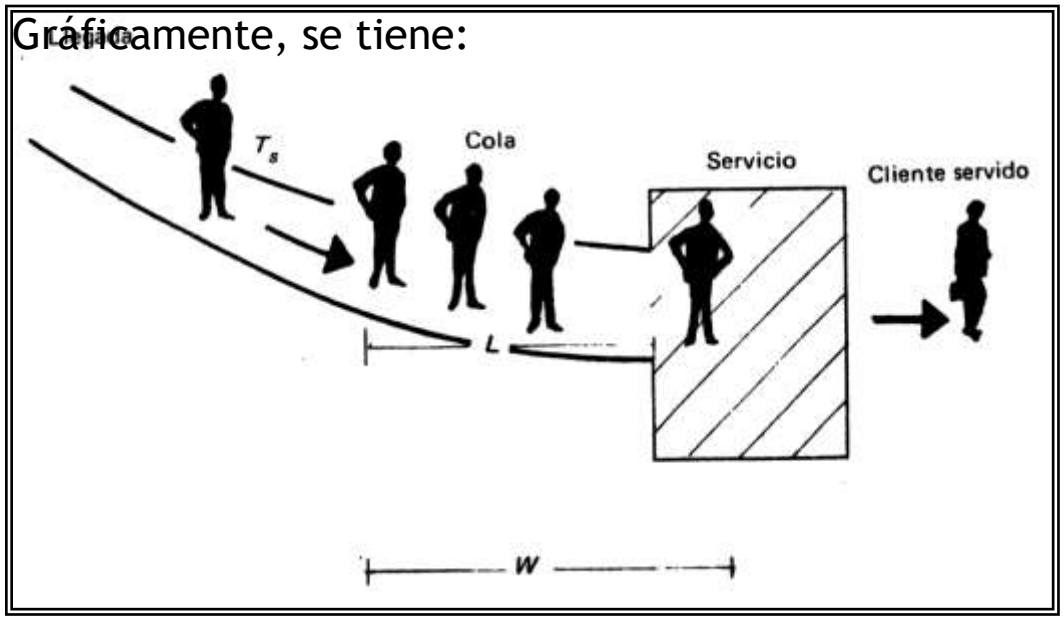
$$\Psi = \frac{\lambda}{\mu S k} \leq 1$$

Esto quiere decir, que el sistema de servidores múltiples podrá dar servicio, por unidad de tiempo, a todas las llegadas en este intervalo de tiempo.

Cuando una persona llega a formarse en una cola, se pregunta: ¿Cuánto tiempo tengo que esperar hasta que me proporcionen servicio (**Wq**)? ¿Cuánto tiempo tengo que esperar hasta que

salga del sistema (**Ws**)? ¿Cuánta gente está esperando en la cola (**Lq)**? ¿Cuánta gente se encuentra en el sistema (**Ls**)?

Gráficamente, se tiene:



Suponga que se dirige al cine, donde estrenan una película ganadora de 13 premios Oscar, y se pregunta, mientras conduce su automóvil, ¿cuál será la probabilidad que se encuentren n personas ($n \geq 0$) en el sistema (1 comprando el boleto, y n-1 formados) en el momento t de formarme en la cola (Pn (t))?. De lo anterior se deduce que p0 (t) es la probabilidad que al llegar usted a la ventanilla del cine en el momento t no haya nadie formado, ni comprando boletos.

En forma resumida se tiene la siguiente notación:

λ : Número promedio de llegadas al sistema por unidad de tiempo.

μ : Número promedio de servicios por unidad de tiempo.

$\rho = \frac{\lambda}{\mu}$: Factor de tráfico con un servidor.

S : Número de servidores en el sistema.

Wq : Tiempo medio de espera en cola.

$$W_q = \frac{\lambda}{\mu (\mu - \lambda)}$$

Ws: Tiempo Total de permanencia del cliente dentro del sistema, conformado por el tiempo de espera en fila más el de atención.

$$W_s = 1 / (\mu - \lambda)$$

Lq: Valor esperado del número de clientes formados en la cola.

$$L_q = \frac{\lambda^2}{\mu (\mu - \lambda)}$$

Ls: Número de clientes en el sistema esperando en la cola y recibiendo un servicio.

$$L_s = \lambda / (\mu - \lambda)$$

p0 (t): Probabilidad de que en el momento t de arribo a la cola, el sistema se encuentre vacío.

$$P_0 = 1 - \lambda / \mu$$

Pn : Probabilidad de que exactamente n clientes se encuentren en el sistema. S recibiendo servicio, en el caso de S (S $\geq$ 1) servidores, y n-S formados en la cola.

$$P_n = P_0(\lambda / \mu)^n$$

ts : Tiempo de servicio por cliente. Es el valor inverso a la velocidad de despacho:

ta : Tiempo de llegada o de arribo por cliente. Es el valor inverso a la velocidad de arribo:

$$t_a = \frac{1}{\lambda}$$

k : Bulk Service, número de clientes atendidos al mismo tiempo por cada canal.

Ψ : Factor de uso, es el cociente entre el factor de trafico y el producto del "número de estaciones", S, por el "Bulk service", k. Para sistemas donde los tiempos de arribo y los tiempos de servicio son determínisticos toma el valor 1, en caso contrario toma un valor inferior a la unidad.

$$\Psi = \frac{\lambda}{\mu S k} = \frac{\rho}{S k}$$

Orientativamente, un buen número es $0.75 < \Psi < 0.8$.